Laboratorio. Árboles y random forest para regresión y clasificación

Nombres: Ponce Proaño Miguel Alejandro

Asignatura: Aprendizaje Automático

Actividad: Nro. 1 - mia05_t6_act

Librerías utilizadas

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.tree import plot_tree
from sklearn import preprocessing
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import r2_score
from sklearn.tree import DecisionTreeRegressor,DecisionTreeClassifier
from sklearn.ensemble import RandomForestRegressor,RandomForestClassifier
from sklearn.model_selection import learning_curve
from sklearn.model_selection import ShuffleSplit
from sklearn.model_selection import cross_val_score
from sklearn.metrics import classification_report
from sklearn.metrics import confusion_matrix
from sklearn.model_selection import KFold
```

- Se crean las constantes que serán utilizadas para el desarrollo del ejercicio. Por ejemplo, el valor de la semilla aleatoria y otras variables.
- Para mostar toda la lista de frecuencias max_mostrar_frecuencias = 0

In [2]:
```
semilla_aleatoria = 1234
cons_no_asignado="NoAsignado"
factor_datos_faltantes = 0.8
max_mostrar_frecuencias = 6
```

1.- Leer los datos del archivo housing_train.csv

In [3]:
```
df_base=pd.read_csv("housing_train.csv")
display(df_base.head(5))
```

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour	Utilities	...	F
0	1	60	RL	65.0	8450	Pave	NaN	Reg	Lvl	AllPub	...	
1	2	20	RL	80.0	9600	Pave	NaN	Reg	Lvl	AllPub	...	
2	3	60	RL	68.0	11250	Pave	NaN	IR1	Lvl	AllPub	...	
3	4	70	RL	60.0	9550	Pave	NaN	IR1	Lvl	AllPub	...	
4	5	60	RL	84.0	14260	Pave	NaN	IR1	Lvl	AllPub	...	

5 rows × 81 columns

2.- Tratamiento de missing. Si existen valores faltantes, decidir si eliminar los registros, llenarlos con valores como la media, la mediana o la moda y justifique su respuesta.

Antes de realizar cualquier evaluación sobre los datos es importante siempre realizar un tratamiento previo a fin de abordar que hacer con la información faltante. Se citan algunos ejemplos:

- Si la cantidad de datos faltantes es muy grande se recomienda borrar estas variables.
- Si existe una cantidad pequeña de filas con datos faltantes en sus variables se puede optar por borrarlas.
- Para variables categóricas se puede agregar un estado adicional que describa este factor.
- Se puede llenar los datos faltantes con la media, mediana o moda de esa variable tanto para variables numéricas o categóricas.
- Para variables categóricas, se puede optar por una asignación aleatoria de categorías escogido aquellas que se encuentren presentes en esa variable, tratado de buscar que se encuentren uniformemente distribuidas.

Tratamiento missing variables numéricas.

- Se selecciona las variables de tipo numérico mediante un filtrado tipos de datos en el csv.

In [4]:
```
datos_numericos = ['int16', 'int32', 'int64', 'float16', 'float32', 'float64']
df_var_numericas = df_base.select_dtypes(include=datos_numericos).copy()
```

Se obtiene las columnas que tienen datos faltantes.

In [5]:
```
col_total_nulos = df_var_numericas.isnull().sum()
serie_col_nombres = col_total_nulos[col_total_nulos > 0]
display(serie_col_nombres)
```

```
LotFrontage    259
MasVnrArea       8
GarageYrBlt     81
dtype: int64
```

Se actualiza por la media de los datos.

- Debido a que la cantidad de datos es muy pequeña se optó por llenar los datos faltantes con la media para buscar su distribución uniforme.

In [6]:
```
for columna in serie_col_nombres.keys():
        mean_col=np.mean(df_var_numericas[columna])
        df_var_numericas[columna].replace(np.nan, mean_col, inplace=True)
display('Verificación de datos faltantes : {0}'.format(df_var_numericas.isnull
().sum().max()))
```

```
'Verificación de datos faltantes : 0'
```

Tratamiento missing variables no numéricas.

- Se selecciona las variables de tipo no numérico mediante un filtrado tipos de datos en el csv.

In [7]:
```
df_var_no_numericas = df_base[df_base.columns.difference(df_var_numericas.columns)].copy()
```

Se estima el factor de datos faltantes.

In [8]:
```
max_factor_moda = len(df_var_no_numericas)*factor_datos_faltantes
display('Máximo fator de datos faltantes : {0}'.format(max_factor_moda))
```

```
'Máximo fator de datos faltantes : 1168.0'
```

Se obtiene las columnas que tienen datos faltantes.

In [9]:
```
total_no_numericas = df_var_no_numericas.isna().sum()
serie_col_nombres = total_no_numericas[total_no_numericas > 0]
display(serie_col_nombres)
```

```
Alley          1369
BsmtCond         37
BsmtExposure     38
BsmtFinType1     37
BsmtFinType2     38
BsmtQual         37
Electrical        1
Fence          1179
FireplaceQu     690
GarageCond       81
GarageFinish     81
GarageQual       81
GarageType       81
MasVnrType        8
MiscFeature    1406
PoolQC         1453
dtype: int64
```

Eliminar columnas que superan factor máximo datos faltantes.

- Debido a que existe una gran cantidad de datos faltantes se borra estas variables ya que no aportan ningún valor al modelo.

In [10]:
```
msk_max_fac_moda = total_no_numericas>max_factor_moda
df_cols_max_factor = total_no_numericas[msk_max_fac_moda]
df_var_no_numericas=df_var_no_numericas.drop(columns=df_cols_max_factor.keys(),
axis=1)
total_no_numericas = df_var_no_numericas.isna().sum()
serie_col_nombres = total_no_numericas[total_no_numericas > 0]
display(serie_col_nombres)
```

```
BsmtCond        37
BsmtExposure    38
BsmtFinType1    37
BsmtFinType2    38
BsmtQual        37
Electrical       1
FireplaceQu    690
GarageCond      81
GarageFinish    81
GarageQual      81
GarageType      81
MasVnrType       8
dtype: int64
```

Reemplazar datos categóricos por la moda.

- Debido a que las categorías tienen pocos datos faltantes y no se puede realizar el cálculo de la media se llena los datos faltantes con la moda.

In [11]:
```
df_cols_min_factor=total_no_numericas[~msk_max_fac_moda]
for columna in df_cols_min_factor.keys():
    val_mediana = df_var_no_numericas[columna].value_counts().idxmax()
    df_var_no_numericas[columna].replace(np.nan, val_mediana, inplace=True)
display('Verificacion actualizacion datos {0}'.format(df_var_no_numericas.isnull
().sum().max()))
```

```
'Verificacion actualizacion datos 0'
```

Para cada categoría se agrega un código que la identifica(variable ficticia).

- Las variables ficticias sirven para representar información cualitativa mediante el uso de estas variables. Estas sirven tantos para modelos de regresión (ficticias aditivas y multiplicativas) y también sirven para medir niveles por categorías.

In [12]:
```
encoder = preprocessing.LabelEncoder()
df_encoder=df_var_no_numericas.apply(encoder.fit_transform)
df_encoder=df_encoder.add_suffix("_c")
df_categorias_encoder=pd.concat([df_var_no_numericas,df_encoder],axis=1)
```

3. De las variables numéricas hallar el valor mínimo, el máximo, la mediana y la media.

- Para seleccionar los tipos de datos numéricos se escoge los tipos que los derriben en una lista, luego se utiliza el método describe(), en donde el percentil 50% equivale a la mediana de los datos.

In [13]:
```
display(df_var_numericas.describe())
```

	Id	MSSubClass	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt	Yea
count	1460.000000	1460.000000	1460.000000	1460.000000	1460.000000	1460.000000	1460.000000	
mean	730.500000	56.897260	70.049958	10516.828082	6.099315	5.575342	1971.267808	
std	421.610009	42.300571	22.024023	9981.264932	1.382997	1.112799	30.202904	
min	1.000000	20.000000	21.000000	1300.000000	1.000000	1.000000	1872.000000	
25%	365.750000	20.000000	60.000000	7553.500000	5.000000	5.000000	1954.000000	
50%	730.500000	50.000000	70.049958	9478.500000	6.000000	5.000000	1973.000000	
75%	1095.250000	70.000000	79.000000	11601.500000	7.000000	6.000000	2000.000000	
max	1460.000000	190.000000	313.000000	215245.000000	10.000000	9.000000	2010.000000	

8 rows × 38 columns

4. De las variables categóricas, listar las diferentes categorías y hallar la frecuencia de cada una de ellas.

- Para el cálculo de frecuencia se las agrupa para cada variable por cada tipo.

In [14]:
```
k=0
for columna in df_var_no_numericas.columns:
    df_frec_cols=df_categorias_encoder[[columna,columna+"_c"]]
    df_frecuencia_cat=df_frec_cols.groupby([columna],as_index=False).size()
    if k<max_mostrar_frecuencias:
        print(df_frecuencia_cat)
    if max_mostrar_frecuencias<=0:
        print(df_frecuencia_cat)
    k=k+1
```

```
BldgType
1Fam      1220
2fmCon      31
Duplex      52
Twnhs       43
TwnhsE     114
dtype: int64
BsmtCond
Fa       45
Gd       65
Po        2
TA     1348
dtype: int64
BsmtExposure
Av     221
Gd     134
Mn     114
No     991
dtype: int64
BsmtFinType1
ALQ    220
BLQ    148
GLQ    418
LwQ     74
Rec    133
Unf    467
dtype: int64
BsmtFinType2
ALQ      19
BLQ      33
GLQ      14
LwQ      46
Rec      54
Unf    1294
dtype: int64
BsmtQual
Ex     121
Fa      35
Gd     618
TA     686
dtype: int64
```

5. Hallar todas las correlaciones existentes entre las variables numéricas del conjunto de datos.

- Se utiliza la función de correlación de las variables, en donde un mejor modelo debe considerar aquellas variables más correladas con la variable a estimar y aquellas variables más decorrelladas entre sí. Aclarar que esto dependerá del método de aprendizaje que utilicemos.

In [15]:
```
display(df_var_numericas.corr())
```

	Id	MSSubClass	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt	YearF
Id	1.000000	0.011156	-0.009601	-0.033226	-0.028365	0.012609	-0.012713	
MSSubClass	0.011156	1.000000	-0.357056	-0.139781	0.032628	-0.059316	0.027850	
LotFrontage	-0.009601	-0.357056	1.000000	0.306795	0.234196	-0.052820	0.117598	
LotArea	-0.033226	-0.139781	0.306795	1.000000	0.105806	-0.005636	0.014228	
OverallQual	-0.028365	0.032628	0.234196	0.105806	1.000000	-0.091932	0.572323	
OverallCond	0.012609	-0.059316	-0.052820	-0.005636	-0.091932	1.000000	-0.375983	
YearBuilt	-0.012713	0.027850	0.117598	0.014228	0.572323	-0.375983	1.000000	
YearRemodAdd	-0.021998	0.040581	0.082746	0.013788	0.550684	0.073741	0.592855	
MasVnrArea	-0.050199	0.022895	0.179283	0.103960	0.410238	-0.127788	0.314745	
BsmtFinSF1	-0.005024	-0.069836	0.215828	0.214103	0.239666	-0.046231	0.249503	
BsmtFinSF2	-0.005968	-0.065649	0.043340	0.111170	-0.059119	0.040229	-0.049107	
BsmtUnfSF	-0.007940	-0.140759	0.122156	-0.002618	0.308159	-0.136841	0.149040	
TotalBsmtSF	-0.015415	-0.238518	0.363358	0.260833	0.537808	-0.171098	0.391452	
1stFlrSF	0.010496	-0.251758	0.414266	0.299475	0.476224	-0.144203	0.281986	
2ndFlrSF	0.005590	0.307886	0.072483	0.050986	0.295493	0.028942	0.010308	
LowQualFinSF	-0.044230	0.046474	0.036849	0.004779	-0.030429	0.025494	-0.183784	
GrLivArea	0.008273	0.074853	0.368392	0.263116	0.593007	-0.079686	0.199010	
BsmtFullBath	0.002289	0.003491	0.091481	0.158155	0.111098	-0.054942	0.187599	
BsmtHalfBath	-0.020155	-0.002333	-0.006419	0.048046	-0.040150	0.117821	-0.038162	
FullBath	0.005587	0.131608	0.180424	0.126031	0.550600	-0.194149	0.468271	
HalfBath	0.006784	0.177354	0.048258	0.014259	0.273458	-0.060769	0.242656	
BedroomAbvGr	0.037719	-0.023438	0.237023	0.119690	0.101676	0.012980	-0.070651	
KitchenAbvGr	0.002951	0.281721	-0.005805	-0.017784	-0.183882	-0.087001	-0.174800	
TotRmsAbvGrd	0.027239	0.040380	0.320146	0.190015	0.427452	-0.057583	0.095589	
Fireplaces	-0.019772	-0.045569	0.235755	0.271364	0.396765	-0.023820	0.147716	
GarageYrBlt	0.000070	0.080187	0.064324	-0.024812	0.518018	-0.306169	0.780555	
GarageCars	0.016570	-0.040110	0.269729	0.154871	0.600671	-0.185758	0.537850	
GarageArea	0.017634	-0.098672	0.323663	0.180403	0.562022	-0.151521	0.478954	
WoodDeckSF	-0.029643	-0.012579	0.077106	0.171698	0.238923	-0.003334	0.224880	
OpenPorchSF	-0.000477	-0.006100	0.137454	0.084774	0.308819	-0.032589	0.188686	
EnclosedPorch	0.002889	-0.012037	0.009790	-0.018340	-0.113937	0.070356	-0.387268	
3SsnPorch	-0.046635	-0.043825	0.062335	0.020423	0.030371	0.025504	0.031355	
ScreenPorch	0.001330	-0.026030	0.037684	0.043160	0.064886	0.054811	-0.050364	
PoolArea	0.057044	0.008283	0.180868	0.077672	0.065166	-0.001985	0.004950	
MiscVal	-0.006242	-0.007683	0.001168	0.038068	-0.031406	0.068777	-0.034383	
MoSold	0.021172	-0.013585	0.010158	0.001205	0.070815	-0.003511	0.012398	
YrSold	0.000712	-0.021407	0.006768	-0.014261	-0.027347	0.043950	-0.013618	
SalePrice	-0.021917	-0.084284	0.334901	0.263843	0.790982	-0.077856	0.522897	

38 rows × 38 columns

6. Determinar el conjunto de modelización y el de validación

- Para determinar el conjunto de modelización se realiza un merge entre el conjunto de variables numéricas y las variables no numéricas (para este caso se toma las variables ficticias). Adicionalmente se excluye la columna Id ya que no es útil para el modelo de estimación. Se separa las variables entre las columnas para realizar la predicción y la columna a predecir el precio de venta de un inmueble(SalePrice).

In [16]:
```
df_data = pd.concat([df_var_numericas,df_encoder],axis=1)
df_data.drop(['Id'], axis=1)
columnas_x=df_data.columns.difference(['SalePrice'])
X=df_data[columnas_x]
Y=df_data['SalePrice']
```

- Se segmenta los datos en dos conjuntos uno de entrenamiento con el 80% y de prueba 20% del total de datos respectivamente.

In [17]:
```
train_x,test_x,train_y,test_y=train_test_split(X,Y,test_size=0.2, random_state =
semilla_aleatoria)
```

7. Pasos regresión método de Árboles

Parametrización del algoritmo de regresión.

In [18]:
```
reg_arboles = DecisionTreeRegressor(max_depth=15,
            max_features='auto', min_samples_leaf=1, min_samples_split=20,
            random_state=semilla_aleatoria, splitter='best')
reg_arboles.fit(train_x,train_y)
```

Out[18]:
```
DecisionTreeRegressor(ccp_alpha=0.0, criterion='mse', max_depth=15,
                      max_features='auto', max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=20,
                      min_weight_fraction_leaf=0.0, presort='deprecated',
                      random_state=1234, splitter='best')
```

Predicción del modelo.

In [19]:
```
predEY_reg_arb=reg_arboles.predict(test_x)
```

Métricas.

In [20]:
```
print('MAE',mean_absolute_error(test_y,predEY_reg_arb))
print('MSE',mean_squared_error(test_y,predEY_reg_arb))
print('R2', r2_score(test_y,predEY_reg_arb))
```

```
MAE 24159.11219788087
MSE 1278008498.6537373
R2 0.7673217151580184
```

Validación cruzada r2 score con mínimo 5 folds

- En general el tratar de que una función aprenda sobre el mismo conjunto de datos sin que exista un conjunto de datos de test se considera como un error metodológico. Es decir que es óptimo para predecir los datos con los que se entrena, pero este generalmente falla al realizar predicciones sobre nuevos conjuntos de datos. Luego podemos utilizar un método de validación cruzada conocido como K-fold cross-validation en donde los datos se dividen en K subconjuntos. Cada subconjunto se utiliza como datos de prueba y el resto (K-1) como datos de entrenamiento.

In [21]:
```
def graficar_r2_scores(estimator, train_x, train_y,test_x,test_y,nparts=5,jobs=None):
    kfold = KFold(n_splits=nparts,shuffle=True, random_state=semilla_aleatoria)
    fig,axes = plt.subplots(figsize=(7, 3))
    axes.set_title("R2/Nro. Fold")
    axes.set_xlabel("Nro. Fold")
    axes.set_ylabel("R2")
    train_scores = cross_val_score(estimator, train_x, train_y, cv = kfold, n_jobs=jobs,scoring="r2")
    test_scores = cross_val_score(estimator, test_x, test_y, cv = kfold, n_jobs=jobs,scoring="r2")
    train_sizes = range(1,nparts+1,1)
    axes.grid()
    axes.plot(train_sizes, train_scores, 'o-', color="r",label="Datos Entrenamiento")
    axes.plot(train_sizes, test_scores, 'o-', color="g",label="Validacion Cruzada")
    axes.legend(loc="best")
    return train_scores
```

In [22]:
```
graficar_r2_scores(reg_arboles,train_x,train_y,test_x,test_y,nparts=5,jobs=2)
```

Out[22]:
```
array([0.84414426, 0.760588  , 0.79611255, 0.74869211, 0.78572832])
```

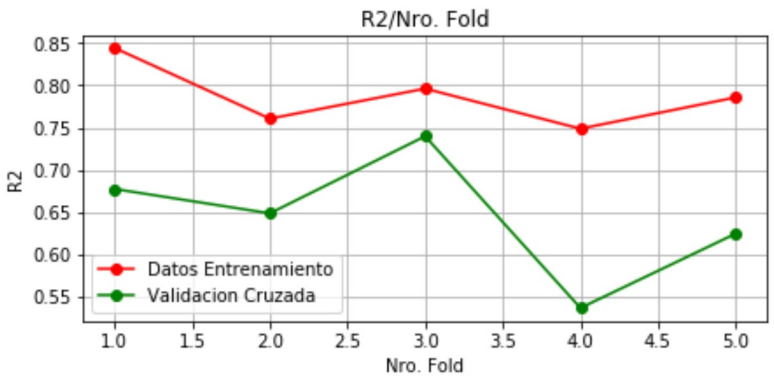

8. Pasos regresión método Random Forest

Parametrización del algoritmo de regresión.

In [23]:
```
reg_rndforest = RandomForestRegressor(n_estimators=100)
reg_rndforest.fit(train_x,train_y)
```

Out[23]:
```
RandomForestRegressor(bootstrap=True, ccp_alpha=0.0, criterion='mse',
                      max_depth=None, max_features='auto', max_leaf_nodes=Non
e,
                      max_samples=None, min_impurity_decrease=0.0,
                      min_impurity_split=None, min_samples_leaf=1,
                      min_samples_split=2, min_weight_fraction_leaf=0.0,
                      n_estimators=100, n_jobs=None, oob_score=False,
                      random_state=None, verbose=0, warm_start=False)
```

Predicción del modelo.

In [24]:
```
predEY_reg_rfor=reg_rndforest.predict(test_x)
```

Métricas.

In [25]:
```
print('MAE',mean_absolute_error(test_y,predEY_reg_rfor))
print('MSE',mean_squared_error(test_y,predEY_reg_rfor))
print('R2', r2_score(test_y,predEY_reg_rfor))
```

```
MAE 17247.943219178083
MSE 727477777.6496911
R2 0.8675530861160197
```

Validación cruzada r2 score con mínimo 5 folds.

In [26]:
```
graficar_r2_scores(reg_rndforest,train_x,train_y,test_x,test_y,nparts=5,jobs=2)
```

Out[26]:
```
array([0.91863702, 0.84651883, 0.83870562, 0.88396926, 0.83417541])
```

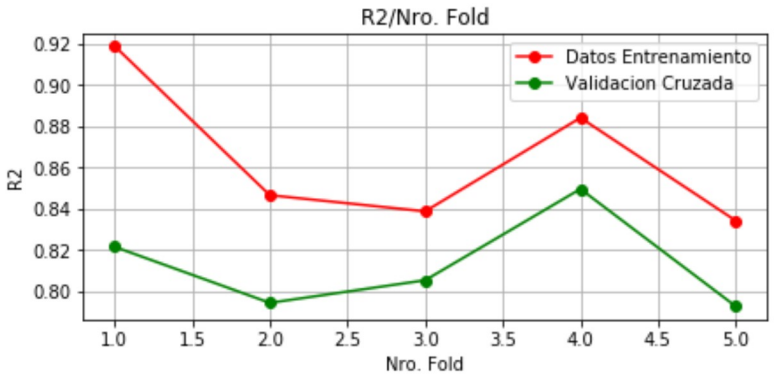

9. Para los métodos de clasificación se crea los siguientes grupos: grupo1 SalePrice menor o igual a 100 000, grupo2 SalePrice entre 101 000 y 500 000 y grupo3 SalePrice mayor o igual a 501 000.

- Se muestra el agrupamiento de datos para cada tipo.

In [27]:
```
df_sp=df_data[['SalePrice']].copy()
df_sp['SalePrice_grupo'] = cons_no_asignado
df_sp['SalePrice_grupo'] = np.where((df_sp['SalePrice'] <=100000),
                                    'grupo1',df_sp['SalePrice_grupo'])
df_sp['SalePrice_grupo'] = np.where((df_sp['SalePrice'] >100000)&(df_sp['SalePri
ce'] <=500000),
                                    'grupo2',df_sp['SalePrice_grupo'])
df_sp['SalePrice_grupo'] = np.where((df_sp['SalePrice'] >501000),
                                    'grupo3',df_sp['SalePrice_grupo'])
display(df_sp['SalePrice_grupo'].value_counts())
```

```
grupo2    1328
grupo1     123
grupo3       9
Name: SalePrice_grupo, dtype: int64
```

10. Determinar el conjunto de modelización y el de validación

- Para determinar el conjunto de modelización se realiza un merge entre el conjunto de variables numéricas y las variables agrupadas por categorías. Adicionalmente se excluye la columna Id ya que no es útil para el modelo de estimación. Se separa las variables entre las columnas para realizar la predicción y la columna a predecir el clasificador por el grupo al que pertenece la venta de un inmueble.

In [28]:
```
df_data = pd.concat([df_var_numericas,df_encoder],axis=1)
df_data.drop(['Id'], axis=1)
columnas_x=df_data.columns.difference(['SalePrice'])
Xc=df_data[columnas_x]
Yc=df_sp['SalePrice_grupo']
```

In [29]:
```
train_xc,test_xc,train_yc,test_yc=train_test_split(Xc,Yc,test_size=0.2, random_s
tate = semilla_aleatoria)
```

11. Pasos método Clasificación método de Árboles

Parametrización del algoritmo de clasificación.

In [30]:
```
clas_arboles = DecisionTreeClassifier(max_depth=15,
            max_features='auto',  min_samples_leaf=1,
            random_state=semilla_aleatoria, splitter='best')
clas_arboles.fit(train_xc,train_yc)
```

Out[30]:
```
DecisionTreeClassifier(ccp_alpha=0.0, class_weight=None, criterion='gini',
                       max_depth=15, max_features='auto', max_leaf_nodes=None,
                       min_impurity_decrease=0.0, min_impurity_split=None,
                       min_samples_leaf=1, min_samples_split=2,
                       min_weight_fraction_leaf=0.0, presort='deprecated',
                       random_state=1234, splitter='best')
```

Predicción del modelo.

In [31]:
```
predEY_clas_arb=clas_arboles.predict(test_xc)
```

Métricas.

In [32]:
```
display(confusion_matrix(test_yc,predEY_clas_arb))
clas_report=classification_report(test_yc,predEY_clas_arb)
print(clas_report)
```

```
array([[ 17,  12],
       [ 19, 244]], dtype=int64)

              precision    recall  f1-score   support

      grupo1       0.47      0.59      0.52        29
      grupo2       0.95      0.93      0.94       263

    accuracy                           0.89       292
   macro avg       0.71      0.76      0.73       292
weighted avg       0.91      0.89      0.90       292
```

Validación cruzada accuracy score con mínimo 5 folds.

In [33]:
```
def graficar_accuracy_scores(estimator, train_x, train_y,test_x,test_y,nparts=5,
jobs=None):
    kfold = KFold(n_splits=nparts,shuffle=True, random_state=semilla_aleatoria)
    fig,axes = plt.subplots(figsize=(7, 3))
    axes.set_title("Ratio de éxito(Accuracy)/Nro. Fold")
    axes.set_xlabel("Nro. Fold")
    axes.set_ylabel("Accuracy")
    train_scores = cross_val_score(estimator, train_x,train_y, cv = kfold, n_job
s=jobs, scoring="accuracy")
    test_scores = cross_val_score(estimator, test_x, test_y, cv = kfold, n_jobs=
jobs, scoring="accuracy")
    train_sizes = range(1,nparts+1,1)
    axes.grid()
    axes.plot(train_sizes, train_scores, 'o-', color="r",label="Datos Entrenamie
nto")
    axes.plot(train_sizes, test_scores, 'o-', color="g",label="Validacion Cruzad
a")
    axes.legend(loc="best")
    return train_scores
```

In [34]:
```
graficar_accuracy_scores(clas_arboles,train_xc,train_yc,test_xc,test_yc,nparts=
5,jobs=2)
```

Out[34]:
```
array([0.91025641, 0.9017094 , 0.94017094, 0.87982833, 0.90128755])
```

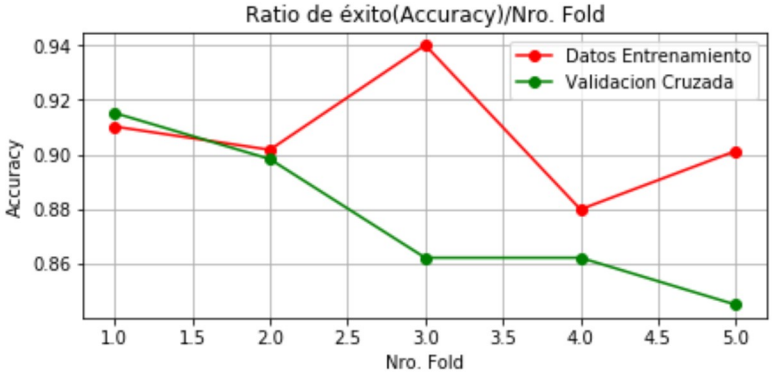

12. Pasos método Clasificación Random Forest

Parametrización del algoritmo de clasificicación.

In [35]:
```
clas_rndforest = RandomForestClassifier(n_estimators=100,n_jobs=2, random_state=
semilla_aleatoria)
clas_rndforest.fit(train_xc,train_yc)
```

Out[35]:
```
RandomForestClassifier(bootstrap=True, ccp_alpha=0.0, class_weight=None,
                       criterion='gini', max_depth=None, max_features='auto',
                       max_leaf_nodes=None, max_samples=None,
                       min_impurity_decrease=0.0, min_impurity_split=None,
                       min_samples_leaf=1, min_samples_split=2,
                       min_weight_fraction_leaf=0.0, n_estimators=100, n_jobs=
2,
                       oob_score=False, random_state=1234, verbose=0,
                       warm_start=False)
```

Predicción del modelo.

In [36]:
```
predEY_clas_rnd=clas_rndforest.predict(test_xc)
```

Métricas.

In [37]:
```
display(confusion_matrix(test_yc,predEY_clas_rnd))
class_report=classification_report(test_yc,predEY_clas_rnd)
print(class_report)
```

```
array([[ 15,  14],
       [  3, 260]], dtype=int64)

              precision    recall  f1-score   support

      grupo1       0.83      0.52      0.64        29
      grupo2       0.95      0.99      0.97       263

    accuracy                           0.94       292
   macro avg       0.89      0.75      0.80       292
weighted avg       0.94      0.94      0.94       292
```

Validación cruzada accuracy score con mínimo 5 folds.

In [38]:
```
graficar_accuracy_scores(clas_rndforest,train_xc,train_yc,test_xc,test_yc,nparts
=5,jobs=2)
```

Out[38]:
```
array([0.94444444, 0.9017094 , 0.96153846, 0.96566524, 0.93562232])
```

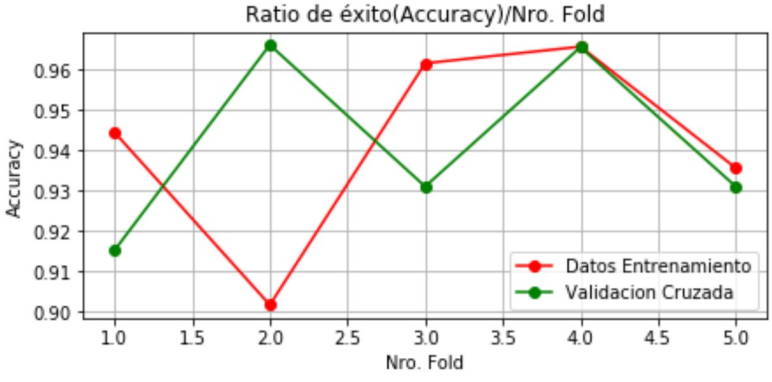

15. Comparar mediante las medidas que parezcan adecuadas la capacidad predictiva de ambos métodos. Es decir, comparar el error cuadrático medio de los dos modelos y concluir cuál es mejor. Seguir el mismo procedimiento con la matriz de confusión de los dos modelos para el ejercicio de clasificación.

- Para las funciones de regresión el método de random forest sus métricas error cuadrático medio es menor y R2 es mayor comparado con el método de arboles de decisión. Por tanto random forest, es el mejor método para predecir un valor en este conjunto de datos.
- Para las funciones de clasificación la matriz de confusión, cuyos valores son métricas de las estimaciones, el método de random forest tiene el valor de ratio de éxito mayor y el valor f1. Por tanto random forest, es el mejor método para clasificar en este conjunto de datos.

14. Comente las ventajas y desventajas de cada modelo. De acuerdo con los resultados, son realmente útiles los modelos creados para el conjunto de datos propuesto o es mejor investigar otros algoritmos.

Random Forest:

Ventajas	Desventajas
* El ratio aproximado de éxito es mayor.	* Mayor tiempo de ejecución.
* Fácil de entrenar	* Es difícil de interpretar
* Random forest previene el overfitting al crear sub-conjuntos aleatorios.	* Los modelos resultado pueden ser muy complejos

Arboles de decisión:

Ventajas	Desventajas
* Tienen un bajo coste computacional.	* Tiene problemas con conjuntos de datos faltantes.
* Es fácil de interpretar y convertir en reglas.	* Tiene problemas con datos complejos.
* • Puede manejar un gran número de cateréticas.	* Pueden sufrir de overfitting ya que dividen o segmentan el espacio de las variables predictoras.

Son realmente útiles los modelos:

Para el problema y el conjunto de datos para la regresión considero que debe considerarse realizar algún método adicional ya que la efectividad en menor al 92% para ambos métodos. Para el caso del problema de clasificación el estimador de Random Forest tiene una mejor ratio de éxito sobre los arboles de decisión incluso al excluir el grupo3 en las categorías clasificar. Finalmente sería bueno realizar un contraste contra algún método adicional.

Por otro lado, y en particular considero que esta pregunta depende de ciertos parámetros adicionales que puedan dar una justificación a priori del si los modelos se ajustan a las necesidades del negocio, proyecto, investigación y etcétera, que consideren que estos resultados realmente pueden representar los datos que esperan o que estos modelos pueden representar una ventaja competitiva. Adicionalmente es importante considerar el ámbito de los datos y el rátio de éxito que se espera de los modelos. Por ejemplo, en aplicaciones críticas, citar el buscar estimar la potencia para un láser en una cirugía ocular. Es decir, es importante un criterio adicional basado en la experiencia de los datos y juicio de expertos que puedan sustentar si el modelo se ajusta al contexto en que se presentó como una posible solución.

En conclusión, se sugiere realizar una contrastación contra otros algoritmos y adicionalmente validar los resultados con juicios de expertos en el contexto que el problema este definido.

15.Otros comentarios que parezcan adecuados.

Presentación de las curvas de aprendizaje para cada modelo

- La curva de aprendizaje es una gráfica del rendimiento del aprendizaje modelo sobre la experiencia o el tiempo. Y estas sirven para diagnosticar un modelo de conjunto, o realizar un ajuste adecuado.

In [39]:
```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import learning_curve
from sklearn.model_selection import ShuffleSplit
def plot_curva_aprendizaje(estimator, title, X, y,n_jobs=None, train_sizes=np.li
nspace(.1, 1.0, 5)):
    cv = ShuffleSplit(n_splits=10, test_size=0.2, random_state=0)
    fig,axes = plt.subplots(figsize=(7, 3))
    axes.set_title(title)
    axes.set_xlabel("Conjuntos Entrenamiento")
    axes.set_ylabel("Score")
    train_sizes, train_scores, test_scores, fit_times, _ = \
        learning_curve(estimator, X, y, cv=cv, n_jobs=n_jobs,
                       train_sizes=train_sizes,
                       return_times=True, random_state=semilla_aleatoria)
    train_scores_mean = np.mean(train_scores, axis=1)
    train_scores_std = np.std(train_scores, axis=1)
    test_scores_mean = np.mean(test_scores, axis=1)
    test_scores_std = np.std(test_scores, axis=1)
    fit_times_mean = np.mean(fit_times, axis=1)
    fit_times_std = np.std(fit_times, axis=1)
    axes.grid()
    axes.fill_between(train_sizes, train_scores_mean - train_scores_std,
                          train_scores_mean + train_scores_std, alpha=0.1,
                          color="r")
    axes.fill_between(train_sizes, test_scores_mean - test_scores_std,
                          test_scores_mean + test_scores_std, alpha=0.1,
                          color="g")
    axes.plot(train_sizes, train_scores_mean, 'o-', color="r",
                 label="Conjunto Entrenamiento")
    axes.plot(train_sizes, test_scores_mean, 'o-', color="g",
                  label="Cross-validation")
    axes.legend(loc="best")
    return plt
```

Curva aprendizaje regresión arboles decisión

In [40]:
```
titulo = "Curva aprendizaje arboles decisión"
plot_curva_aprendizaje(reg_arboles, titulo , train_x, train_y, n_jobs=2)
```

Out[40]:
```
<module 'matplotlib.pyplot' from 'C:\\ProgramData\\Anaconda3\\lib\\site-packag
es\\matplotlib\\pyplot.py'>
```

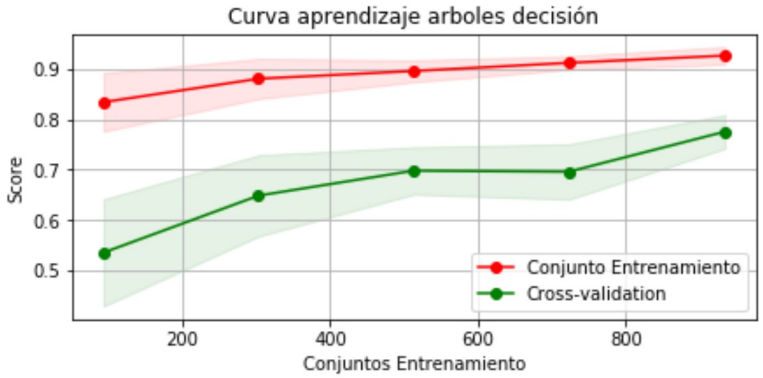

Curva aprendizaje regresión random forest

In [41]:
```
titulo = "Curva aprendizaje random forest"
plot_curva_aprendizaje(reg_rndforest, titulo, train_x, train_y, n_jobs=2)
```

Out[41]:
```
<module 'matplotlib.pyplot' from 'C:\\ProgramData\\Anaconda3\\lib\\site-packag
es\\matplotlib\\pyplot.py'>
```

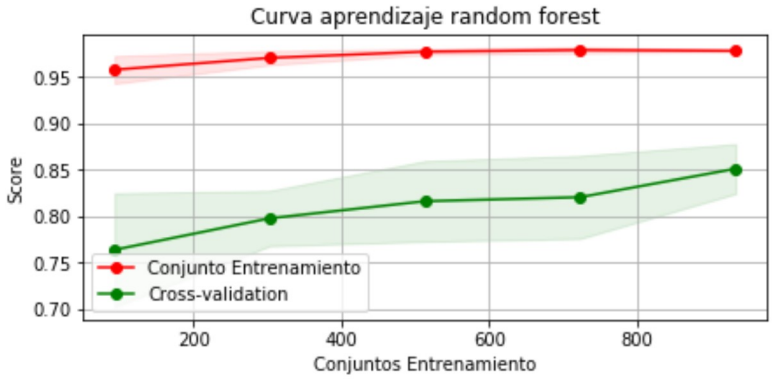

Curva aprendizaje clasificación arboles decisión

In [42]:
```
titulo = "Curva aprendizaje arboles decisión"
plot_curva_aprendizaje(clas_arboles, titulo , train_xc, train_yc, n_jobs=2)
```

Out[42]:
```
<module 'matplotlib.pyplot' from 'C:\\ProgramData\\Anaconda3\\lib\\site-packag
es\\matplotlib\\pyplot.py'>
```

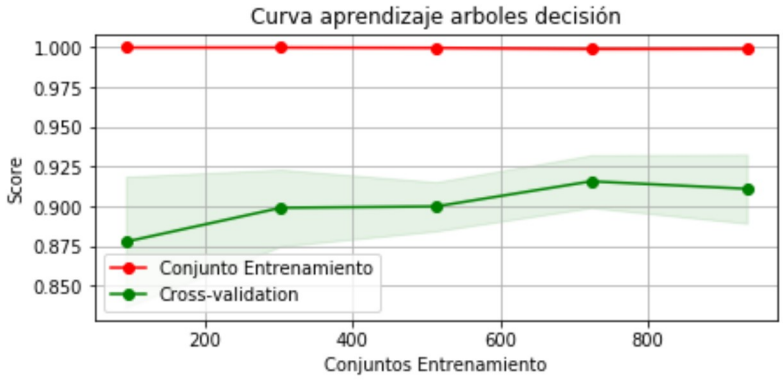

Curva aprendizaje clasificación random forest

In [43]:
```
titulo = "Curva aprendizaje random forest"
plot_curva_aprendizaje(clas_rndforest, titulo , train_xc, train_yc, n_jobs=2)
```

Out[43]:
```
<module 'matplotlib.pyplot' from 'C:\\ProgramData\\Anaconda3\\lib\\site-packag
es\\matplotlib\\pyplot.py'>
```